

基于特征迁移学习的变工况下 滚动轴承故障诊断方法

康守强¹, 胡明武¹, 王玉静¹, 谢金宝¹, V.I. Mikulovich²

(1. 哈尔滨理工大学电气与电子工程学院, 黑龙江省 哈尔滨市 150080;

2. 白俄罗斯国立大学, 白俄罗斯 明斯克 220030)

Fault Diagnosis Method of a Rolling Bearing Under Variable Working Conditions Based on Feature Transfer Learning

KANG Shouqiang¹, HU Mingwu¹, WANG Yujing¹, XIE Jinbao¹, V.I. Mikulovich²

(1. School of Electrical and Electronic Engineering, Harbin University of Science and Technology, Harbin 150080,

Heilongjiang Province, China; 2. Belarusian State University, Minsk 220030, Belarus)

ABSTRACT: For a rolling bearing, especially under variable working conditions, it is difficult and even unable to obtain a large number of tagged vibration data, and then the fault diagnosis accuracy is low, a new fault diagnosis method of the rolling bearings is proposed based on variational mode decomposition (VMD) and multiple feature structure combined with transfer learning. By using VMD, each state vibration signal of the rolling bearing is decomposed into a series of intrinsic mode function (IMF) components, then the singular values of the IMF matrix can be obtained by singular value decomposition, and the singular value entropy can be calculated. The multiple feature set is constructed with the singular values, the singular value entropy, the time domain and frequency domain features. At the same time, semisupervised transfer component analysis (SSTCA) is introduced, and its kernel is constructed as the multi-kernel function. The sample features of different working conditions are all mapped to a shared reproducing kernel Hilbert space, and which can improve the compactness and interclass distinction of the data. By using the maximum mean discrepancy embedding method, more effective data are selected and regarded as the source domain. The source domain feature samples are input into support vector machine (SVM), and then the feature samples of the mapped target domain are

tested. The experimental results show that, compared with other methods, the proposed multi-kernel SSTCA-SVM method has a higher accuracy in the multi-state classification of the rolling bearings under variable working conditions.

KEY WORDS: variable working conditions; rolling bearing; semisupervised transfer component analysis(SSTCA); transfer learning; variational mode decomposition(VMD)

摘要: 针对滚动轴承尤其是变工况条件下很难或无法获取大量带标签的振动数据, 以致诊断准确率低的问题, 提出一种基于变分模态分解(variational mode decomposition, VMD)及多特征构造和迁移学习相结合的滚动轴承故障诊断方法。该方法利用 VMD 对滚动轴承各状态振动信号进行分解, 得到一系列固有模态函数, 对其构成的矩阵进行奇异值分解求奇异值及奇异值熵, 再结合振动信号的时域、频域特征构造多特征集。同时引入半监督迁移成分分析方法(semisupervised transfer component analysis, SSTCA), 并对其核函数进行多核构造, 将不同工况样本特征共同映射到一个共享再生核 Hilbert 空间, 进而提高数据类内紧凑性和类间区分性。采用最大均值差异嵌入法选择更有效的数据作为源域, 将源域特征样本输入支持向量机(support vector machine, SVM)进行训练, 测试映射后的目标域特征样本。实验表明, 所提多核 SSTCA-SVM 方法与其他方法相比较, 在变工况下滚动轴承多状态分类中具有更高准确率。

关键词: 变工况; 滚动轴承; 半监督迁移成分分析(SSTCA); 迁移学习; 变分模态分解(VMD)

0 引言

滚动轴承作为大型旋转机械设备的關鍵部件之一, 对其进行有效的故障诊断有利于预防设备事

基金项目: 国家自然科学基金项目(51805120, 51305109); 黑龙江省本科高校青年创新人才培养计划(UNPYSCT-2017091); 哈尔滨理工大学青年拔尖创新人才资助项目(201511)。

Project Supported by National Natural Science Foundation of China (51805120, 51305109); University Nursing Program for Young Scholars with Creative Talents in Heilongjiang Province (UNPYSCT-2017091); Science Funds for the Young Innovative Talents of HUST(201511).

故发生^[1]。滚动轴承在实际工作时, 工况常常是变化的。近年来, 对变工况下滚动轴承故障诊断的研究受到学者的广泛关注。

文献[2]结合希尔伯特黄变换与奇异值分解(singular value decomposition, SVD)对滚动轴承振动信号进行特征提取, 再利用递归神经网络实现变工况下轴承故障分类; 文献[3]利用包络分析结合多尺度熵和经验模态分解方法实现变转速下滚动轴承故障诊断; 文献[4]将二进制差异演化与 k 近邻分类算法相结合, 实现了变工况下滚动轴承故障诊断; 文献[5]利用改进的相关向量机和自适应特征选择方法, 建立了变负载下轴承的故障分类模型。上述文献所述方法, 在一定程度上实现了变工况下滚动轴承的故障分类, 但传统的机器学习方法对训练和测试数据分布存在差异时, 所建立的分类模型泛化能力差, 甚至不适用^[6]。

为了打破传统机器学习的局限性, 近年来迁移学习的应用非常广泛。迁移学习方法不需像传统机器学习要求训练数据与测试数据作同分布假设, 并且它可避免传统机器学习中对获得的数据重新标定标签所带来的人力、物力的耗费^[7]。迁移学习的主要思想是从现有源域中学到知识, 再将这些知识迁移到目标域, 以完成目标域的分类。变工况下滚动轴承故障诊断时, 数据分布恰恰不满足同分布条件, 同时对新获得的工况数据进行标注是非常困难的。文献[8]提出基于自相关矩阵 SVD 的特征提取方法与迁移学习相结合, 实现了电机的故障诊断。文献[9]提出一种最小二乘支持向量机(support vector machine, SVM)的迁移学习方法, 所提模型对轴承诊断性能有所提升。文献[10]构建了改进贝叶斯神经网络的迁移学习算法, 应用于遥感影像分类, 获得了较好效果。上述采用基于样本的迁移学习方法实现故障诊断, 但该方法要求不同分布数据间差异尽可能小^[11]。区别于样本迁移方法, 基于特征的迁移学习方法在数据分布差异大的情况下, 通过特征变换或特征选择, 仍可实现不同分布数据差异最小化^[12]。

文献[13]提出固有子空间分析方法(stationary subspace analysis, SSA)实现不同分布数据在空间中的匹配; 文献[14]提出信息理论学习(information theoretical learning, ITL)方法度量不同数据样本间共用知识; 文献[15]采用测地线流式核(geodesic flow kernel, GFK)方法, 在格拉斯曼流形空间中度

量不同分布数据几何距离; 文献[16]提出子空间对齐法(subspace alignment, SA)直接寻找一个线性变换将源域变换到目标域中, 实现不用领域数据分布差异最小化。除此之外, 特征迁移方法中的半监督迁移成分分析方法(semisupervised transfer component analysis, SSTCA)将不同特征样本映射到一个共享再生核 Hilbert 空间, 在核空间中采用希尔伯特施密特独立标准(hilbert-schmidt independence criterion, HSIC)度量样本特征与样本类别间的依赖程度, 以提高样本特征与其类别之间的关联性^[12]。同时, 该方法具有局部几何结构保持项, 保持数据特征映射后在核空间中的几何结构, 可提高数据的类内紧凑性与类间区分性^[12]。

因此, 本文引入 SSTCA 方法对变工况下滚动轴承的振动特征进行迁移, 但该方法在遇到数据异构、多特征和大规模样本时, 其单核函数存在泛化能力局限和鲁棒性不足的问题。为解决该问题, 对其核函数进行改进, 采用多核学习的方法构建多核函数, 从而获得更佳的特征映射空间, 以此进一步提高核空间的映射效果, 在核空间中实现数据的表达更具灵活性, 缩小不同领域数据分布的差异, 提高变工况下滚动轴承的振动特征的迁移效果。同时, 采用最大均值差异嵌入方法(maximum mean discrepancy embedding, MMDE), 度量源域数据到目标域数据的可迁移性, 以避免“负迁移”, 进一步结合 SVM 实现变工况下滚动轴承多状态故障分类。

1 变分模态分解原理

变分模态分解(variational mode decomposition, VMD)过程分为变分问题的构造和求解 2 个部分^[17]。

1) 变分问题的构造。

假设原始信号 f 可得到 k 个模态分量 $u_k(t)$, 其经 Hilbert 变换获得各模态分量 $u_k(t)$ 的解析信号, 并得到 $u_k(t)$ 的单边频谱:

$$[\delta(t) + j/\pi t]u_k(t) \quad (1)$$

式中 $\delta(t)$ 为冲激函数。

对每个解析信号混合-预估中心频率 $e^{j\omega_k t}$, 将各模态的频谱调制到基频带上, 得到:

$$\{[\delta(t) + j/\pi t]u_k(t)\}e^{-j\omega_k t} \quad (2)$$

式中 ω_k 表示第 k 个模态分量的中心频率。

计算式(2)梯度的平方 L^2 范数, 估计出各模态信号的带宽, 受约束的变分问题表示为

$$\begin{cases} \min_{\{u_k\}, \{\omega_k\}} \left\{ \sum_{k=1}^K \left\| \partial_t \{ [\delta(t) + j / \pi t] u_k(t) \} e^{-j\omega_k t} \right\|_2^2 \right\} \\ \text{s.t.} \quad \sum_{k=1}^K u_k = f \end{cases} \quad (3)$$

式中: ∂_t 为对 t 求偏导数; $\{u_k\} := \{u_1, u_2, \dots, u_K\}$; $\{\omega_k\} := \{\omega_1, \omega_2, \dots, \omega_K\}$ 。

2) 变分问题的求解。

为了将变分问题由约束性变成非约束性, 引入二次惩罚因子 α 和拉格朗日乘法算子 $\lambda(t)$ 。二次惩罚因子保证信号的重构精度, 拉格朗日算子使约束条件保持严格性。扩展的拉格朗日表达式为

$$\begin{aligned} L(\{u_k\}, \{\omega_k\}, \{\lambda\}) := & \alpha \sum_{k=1}^K \left\| \partial_t \{ [\delta(t) + \right. \\ & \left. \frac{j}{\pi t}] u_k(t) \} e^{-j\omega_k t} \right\|_2^2 + \left\| f(t) - \sum_{k=1}^K u_k(t) \right\|_2^2 + \\ & \left\langle \lambda(t), f(t) - \sum_{k=1}^K u_k(t) \right\rangle \end{aligned} \quad (4)$$

求解式(4)变分问题, 采用乘法算子交替方向法, 通过迭代更新 u_k^{n+1} 、 ω_k^{n+1} 和 λ^{n+1} 寻求拉格朗日扩展表达式的“鞍点”, 即为变分问题的最优解。在迭代时为了使计算简便, 将 u_k^{n+1} 、 ω_k^{n+1} 变换到频域, 求取 $u_k^{n+1}(\omega)$ 的更新过程:

$$\hat{u}_k^{n+1}(\omega) = \frac{\hat{f}(\omega) - \sum_{i \neq k} \hat{u}_i(\omega) + \hat{\lambda}(\omega) / 2}{1 + 2\alpha(\omega - \omega_k)^2} \quad (5)$$

中心频率更新过程:

$$\omega_k^{n+1} = \frac{\int_0^\infty \omega |\hat{u}_k(\omega)|^2 d\omega}{\int_0^\infty |\hat{u}_k(\omega)|^2 d\omega} \quad (6)$$

综合式(5)、(6)对 $\{\hat{u}_k(\omega)\}$ 进行傅里叶逆变换, 得到其实部即为 $\{u_k(t)\}$ 。

2 奇异值与奇异值熵

SVD 本身具有较好的稳定性和不变性^[18]。假设 X 是 $m \times n$ 的矩阵 ($m > n$), 秩为 r ($r \leq n$), 现有 $m \times m$ 的正交矩阵 U 和 $n \times n$ 的正交矩阵 V , 使得:

$$U^T X V = A \quad (7)$$

式中 A 为 $m \times n$ 的非负对角阵:

$$A = \begin{bmatrix} S & 0 \\ 0 & 0 \end{bmatrix} \quad (8)$$

式中 $S = \text{diag}(e_1, e_2, \dots, e_r)$, e_1, e_2, \dots, e_r 为 X 的奇异值。

奇异值包含振动信号的不同故障特征, 为了定量描述这种变化, 用信息熵理论求出奇异值熵^[19]。

各固有模态函数(intrinsic mode function, IMF)有不同的频率成分, 且分解后的奇异值也不同, 对各分量归一化, 得到 $T_i = e_i^2 / E$, 其中 $E = E_1 + E_2 + \dots + E_n$, $E_i = e_i^2$, $i = 1, 2, \dots, n$ 。得到每个模态分量奇异值熵为

$$H = - \sum_{i=1}^n p_i \ln p_i \quad (9)$$

式中: $p_i = T_i / T$, $T = \sum_{i=1}^n T_i$ 。

3 基于特征的迁移学习

3.1 领域适应性方法

假设源域为 $D_S = \{X_S, Y_S\}$, X_S 为源域特征样本集, Y_S 为标签空间。目标域为 $D_T = \{X_T\}$, X_T 为目标域特征样本集, 目标域特征样本的标签未知。领域适应性方法特征映射过程示意图如图1所示。




图1 领域适应性方法示意图

Fig. 1 Schematic diagram of the domain adaptation method

领域适应性方法可减小源域数据与目标域数据之间的分布差异, 将源域特征样本集和目标域特征样本集共同进行特征映射, 用 Φ 表示映射关系, 即为 $X_S \cup X_T \rightarrow \Phi(X_S \cup X_T)$ 。共同特征映射前, 源域特征样本集与目标域特征样本集的边缘概率分布不同 $P(X_S) \neq P(X_T)$ 。特征映射后, $\Phi(X_S)$ 与 $\Phi(X_T)$ 的边缘概率分布尽可能相似 $P[\Phi(X_S)] \approx P[\Phi(X_T)]$ 。源域特征样本集与目标域特征样本集特征映射到共享子空间, 充分利用特征样本可迁移知识, 提高跨领域的学习能力。

3.2 多核半监督迁移成分分析

3.2.1 多核核函数构造

采用单一核函数处理分布不均衡数据时, 其效果通常不够理想^[20]。对于变工况下滚动轴承振动信号数据, 也存在不同状态数据分布不均衡的情况。为了改变单一核函数处理变工况下滚动轴承数据

的不足,利用多种基本核函数进行凸组合,以达到最佳特征映射目的。多核核函数构造的表达式为

$$K(x_i, x_j) = \sum_{m=1}^M a_m K_m(x_i, x_j) \quad (10)$$

式中: M 为核函数的个数,核函数的权值 $a_m \geq 0$, 且 $a_1 + a_2 + \dots + a_M = 1$ 。

根据 Mercer 定理及滚动轴承数据分布特性,采用具有全局特性的多项式核函数和满足局部特性的高斯径向基核函数加权求和,构造多核核函数:

$$K_{i,j} = aK_{\text{poly}} + (1-a)K_{\text{rbf}} \quad (11)$$

式中: a 为多核系数,且 $0 \leq a \leq 1$; K_{poly} 为多项式核函数; K_{rbf} 为高斯径向基核函数。

3.2.2 半监督迁移成分分析(SSTCA)

假设 $\Phi(X_S)$ 与 $\Phi(X_T)$ 是经过再生核 Hilbert 空间映射后的源域特征样本集与目标域特征样本集, MMDE 度量表示为

$$\text{Dist}[\Phi(X_S), \Phi(X_T)] = \left\| \frac{\sum_{i=1}^{n_S} \Phi(X_{S_i})}{n_S} - \frac{\sum_{j=1}^{n_T} \Phi(X_{T_j})}{n_T} \right\|_H^2 \quad (12)$$

式中: n_S 为源域特征样本个数; n_T 为目标域特征样本个数。

为减少 MMDE 计算复杂性,利用矩阵变换表示 MMDE 为

$$\text{Dist}[\Phi(X_S), \Phi(X_T)] = \text{trace}(\mathbf{KL}) \quad (13)$$

式中: trace 表示求矩阵的迹。核矩阵 \mathbf{K} 为

$$\mathbf{K} = \begin{bmatrix} \mathbf{K}_{S,S} & \mathbf{K}_{S,T} \\ \mathbf{K}_{T,S} & \mathbf{K}_{T,T} \end{bmatrix} \in \mathbb{R}^{(n_S+n_T) \times (n_S+n_T)} \quad (14)$$

式(13)中, \mathbf{L} 为

$$\mathbf{L}_{i,j} = \begin{cases} 1/n_S^2, & \text{if } x_i, x_j \in X_S \\ 1/n_T^2, & \text{if } x_i, x_j \in X_T \\ -1/(n_S n_T), & \text{其他} \end{cases} \quad (15)$$

式(14)中: $\mathbf{K}_{S,S}$, $\mathbf{K}_{T,T}$, $\mathbf{K}_{S,T}$, $\mathbf{K}_{T,S}$ 分别表示定义在源域、目标域及跨域的核矩阵。核矩阵中的元素为 $K_{i,j} = \Phi(x_i)^T \Phi(x_j)$, $K_{i,j}$ 表示核函数。核矩阵 \mathbf{K} 表示为

$$\mathbf{K} = (\mathbf{K}\mathbf{K}^{-1/2})(\mathbf{K}^{-1/2}\mathbf{K}) \quad (16)$$

使用矩阵 $\tilde{\mathbf{W}} \in \mathbb{R}^{(n_S+n_T) \times m}$ 将核映射到 m 维空间上 ($m \leq n_S + n_T$), 核矩阵 \mathbf{K} 变换为

$$\tilde{\mathbf{K}} = (\mathbf{K}\mathbf{K}^{-1/2}\tilde{\mathbf{W}})(\tilde{\mathbf{W}}^T\mathbf{K}^{-1/2}\mathbf{K}) = \mathbf{K}\mathbf{W}\mathbf{W}^T\mathbf{K} \quad (17)$$

式中 $\mathbf{W} = \mathbf{K}^{-1/2}\tilde{\mathbf{W}}$ 。

根据式(17)将式(13)变换成:

$$\text{Dist}[\Phi(X_S), \Phi(X_T)] = \text{trace}[(\mathbf{K}\mathbf{W}\mathbf{W}^T\mathbf{K})\mathbf{L}] = \text{trace}(\mathbf{W}^T\mathbf{K}\mathbf{L}\mathbf{K}\mathbf{W}) \quad (18)$$

SSTCA 方法引入希尔伯特施密特独立标准 (Hilbert-Schmidt independence criterion, HSIC)^[21], 其作为一种基于核的独立性度量方法,在再生核希尔伯特空间上采用互协方差算子推导出统计量,衡量样本特征与样本类别间的依赖程度,其表达式为

$$\text{HSIC}(X, Y) = [1/(n_S + n_T - 1)^2] \text{trace}(\mathbf{H}\mathbf{K}\mathbf{H}\mathbf{K}_{yy}) \quad (19)$$

式中: X 为核空间中特征样本; Y 为源域特征样本相应的类别标签; 中心矩阵 $\mathbf{H} = \mathbf{I}_{n_S+n_T} - [1/(n_S + n_T)]\mathbf{1}\mathbf{1}^T$, $\mathbf{1}$ 为全为 1 的列向量, \mathbf{I} 为单位矩阵; \mathbf{K}_{yy} 为定义在源域特征样本上的核矩阵。

为实现输入特征样本 x_i 与 x_j 在经特征映射变换后距离最小化,特征样本约束函数为

$$\frac{\sum_{i,j} \mathbf{M}_{i,j} \|x_i^* - x_j^*\|^2}{(n_S + n_T)^2} = \frac{\text{trace}(\mathbf{W}^T\mathbf{K}\mathbf{K}\mathbf{W})}{(n_S + n_T)^2} \quad (20)$$

式中: x_i^* 和 x_j^* 分别为 x_i 和 x_j 特征映射后的特征样本。拉普拉斯矩阵 $\mathbf{L} = \mathbf{D} - \mathbf{M}$, 当输入的特征样本 x_i 与 x_j 满足在 k 近邻范围内, $\mathbf{M} = [m_{ij}]$, $m_{ij} = \exp(-d_{ij}^2 / 2\sigma^2)$, d_{ij} 为输入特征样本之间的欧几里得距离, σ 为参数。 \mathbf{D} 为对角矩阵, 构成:

$$\mathbf{D}_{i,i} = \sum_{j=1}^{n_S+n_T} \mathbf{M}_{i,j} \quad (21)$$

综上所述,结合式(18)、(19)和(20),多核 SSTCA 方法目标函数为

$$\begin{cases} \min_{\mathbf{W}} = \text{trace}(\mathbf{W}^T\mathbf{K}\mathbf{L}\mathbf{K}\mathbf{W}) + \mu \text{trace}(\mathbf{W}^T\mathbf{W}) + \\ \quad \lambda / (n_S + n_T) \text{trace}(\mathbf{W}^T\mathbf{K}\mathbf{L}\mathbf{K}\mathbf{W}) \\ \text{s.t. } \mathbf{W}^T\mathbf{K}\mathbf{H}\mathbf{K}_{yy}^*\mathbf{H}\mathbf{K}\mathbf{W} = \mathbf{I} \end{cases} \quad (22)$$

式中: 标签索引矩阵 $\mathbf{K}_{yy}^* = \gamma\mathbf{K}_{yy} + (1-\gamma)\mathbf{I}$; γ 为特征样本类别标签索引参数; $\text{trace}(\mathbf{W}^T\mathbf{W})$ 是正则化项; μ 为正则化参数; λ 为保持数据局部特性的权衡系数,且 $\lambda \geq 0$ 。求取式(22)的目标函数,即可得到最佳映射核矩阵 \mathbf{W} 。

4 变工况下滚动轴承识别方法及流程

基于特征多核 SSTCA-SVM 变工况下滚动轴承故障诊断方法流程图如图 2 所示。

1) 对已知工况和未知工况滚动轴承多状态(不同转速和不同负载工况下的正常、内环不同故障程

度、外环不同故障程度、滚动体不同故障程度)振动信号进行 VMD 操作,用观察法确定分解的 IMF 个数^[17],对 IMF 构建矩阵,并进行 SVD 获取奇异值,同时求取奇异值熵。再提取振动信号的时域、频域特征指标。

2) 将式(1)中已知工况滚动轴承振动信号的时域、频域特征,结合奇异值、奇异值熵共同构建源域训练特征样本集;同理,未知工况的滚动轴承振动特征构建目标域测试特征样本集。

3) 将式(2)中源域特征样本集与目标域特征样本集共同特征映射到再生核 Hilbert 空间中,在该空间中用 MMDE 度量源域特征样本与目标域特征样本之间的最大均值距离。由最大均值差异统计值判断可迁移源域数据,选择合适源域振动信号数据辅助目标域学习,提高对目标域数据类别识别能力。

4) 将式(3)中映射后已标记源域特征样本集输入 SVM 中,同时用遗传算法(genetic algorithm, GA)对惩罚因子和径向基核参数进行寻优,最终得到训练模型。将映射后的目标域特征样本集输入到模型中,获得未知变工况下滚动轴承故障识别结果。

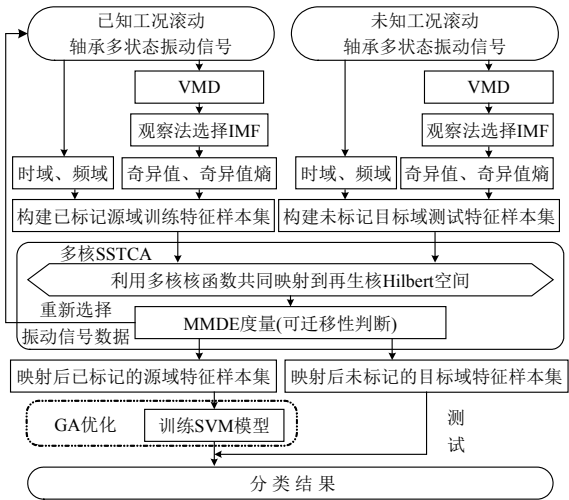


图 2 变工况下滚动轴承故障诊断方法流程图
Fig. 2 Flowchart of fault diagnosis method for rolling bearing under variable working conditions

5 应用与分析

5.1 实验条件与参数

实验数据来自美国凯斯西储大学电气工程实验室滚动轴承数据中心。测试系统包括驱动电机和负载以及控制电路,数据通过 16 通道的数据记录仪采集得到,采样频率包括 12 kHz 和 48 kHz。

本实验选用电机驱动端深沟球滚动轴承,型号为 SKF6205,采样频率 48 kHz 实验数据。滚动轴承内环损伤直径分别为 0.1778, 0.3556, 0.5334mm,

同时不同损伤直径包括不同负载、不同转速的变工况下滚动轴承振动信号数据。内环故障状态分为 3 类如表 1 所示,其中 hp 为英制的马力,1hp=0.75kW。同理,滚动轴承外环、滚动体故障状态各有 3 类,另加正常状态一共分为 10 类。

表 1 滚动轴承变工况下内环故障状态

Tab. 1 Fault states of inner ring of rolling bearing under variable working conditions

损伤直径	0.1778 mm	0.3556mm	0.5334mm
不同工况	0hp, 1797r/min	0hp, 1797r/min	0hp, 1797r/min
	1hp, 1772r/min	1hp, 1772r/min	1hp, 1772r/min
	2hp, 1750r/min	2hp, 1750r/min	2hp, 1750r/min
	3hp, 1730r/min	3hp, 1730r/min	3hp, 1730r/min

实验设置滚动轴承 10 类状态 4 种工况条件下数据样本集: 1) 工况 A 为 0hp, 1797r/min 数据样本集; 2) 工况 B 为 1hp, 1772r/min 数据样本集; 3) 工况 C 为 2hp, 1750r/min 数据样本集; 4) 工况 D 为 3hp, 1730r/min 数据样本集。数据样本集组成如表 2 所示,其中“多/单工况”表示滚动轴承 10 类状态中多种工况下特征样本集 ACD 作为源域数据,即训练特征样本集,单一工况下特征样本集 B 作为目标域数据,即测试特征样本集,其他以此类推。

表 2 不同工况滚动轴承数据样本集构成


Tab. 2 Data set composition of rolling bearings under different working conditions

工况	源域	目标域	源域样本数/个	目标域样本数/个
单/单工况	C	B	1100	900
多/多工况	AC	BD	1600	2000
多/单工况	ACD	B	2700	900

5.2 多特征构造

首先,利用 VMD 得到若干 IMF,采用通过观察中心频率变化的方法确定模态数 N ^[17]。以 1hp, 1772r/min 工况的滚动轴承内环故障振动信号进行 VMD 操作为例,每个样本取振动信号 4096 点。分解得到不同模态数 N 所对应的中心频率结果如图 3 所示。

由图 3 可见,当模态数 N 大于 4 时不同中心频率线出现重叠现象,说明产生过分解;当模态数 N



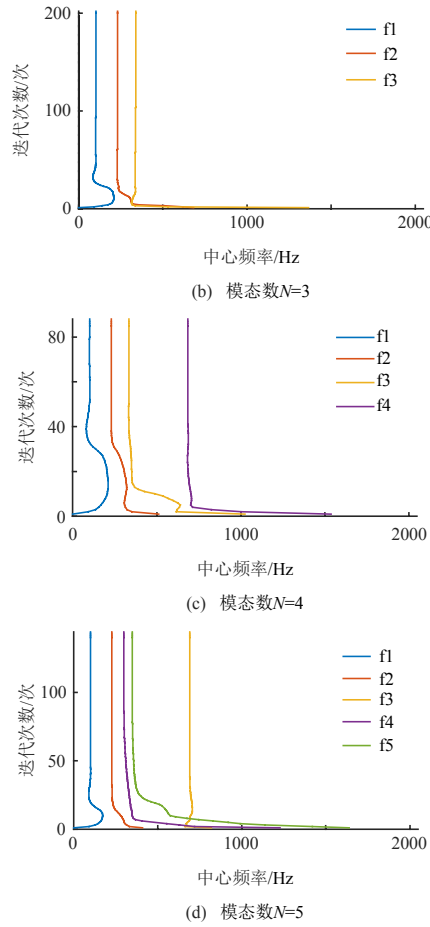


图3 不同 N 值对应的中心频率分布
Fig. 3 Central frequency distribution corresponding to different N values

小于4时不同中心频率线出现分解不完全,即欠分解现象,故确定模态数为4。模态数被确定后,VMD结果如图4所示,VMD结果各分量频谱图如图5所示。

采用同样的方法对变工况下滚动轴承振动信号进行VMD获取IMF,并组成矩阵,求取奇异值和奇异值熵。因不同振动信号分解得到的IMF个数




图4 VMD结果图
Fig. 4 VMD results diagram




图5 VMD结果各分量频谱图
Fig. 5 Spectrum diagram of each component

可能不同,为便于后续处理,IMF个数少的补充零向量,使提取的特征维数一致。同时,提取滚动轴承振动信号均方根值、峰值指标、峰-峰值、波形指标、脉冲指标、裕度指标、峭度指标7个时域特征指标,并提取重心频率、均方频率、均方根频率、频率方差及频域特征指标 F_1 — F_{13} 共17个频域特征指标,详见文献[22]。

综上,将滚动轴承故障振动信号提取得到的奇异值、奇异值熵,以及时域、频域特征指标构造多特征集,并且为消除不同特征数据的量纲影响,对多特征集进行归一化处理。

5.3 可迁移性判断

根据统计学理论,MMDE方法在再生核Hilbert空间中,用源域数据和目标域数据之间的总体最大均值之差表明2个领域间的分布差异。实验用变工况下滚动轴承源域特征样本集A、B、C、D分别与目标域特征样本集A、B、C、D作最大均值差异度量,得到最大均值差异统计值见表3。表3中源域特征样本集与目标域特征样本集间的最大均值差异越小,说明源域到目标域的可迁移性越强,这有利于选择与目标域数据相似性高的源域数据辅助目标域数据分类。

表3 最大均值差异统计值表
Tab. 3 Maximum mean difference statistical value list

统计值		目标域特征样本集			
		A	B	C	D
源域特征样本集	A	—	0.152 3	0.181 1	1.008 4
	B	0.152 3	—	0.132 7	0.968 9
	C	0.181 1	0.132 7	—	0.964 2
	D	1.008 4	0.968 9	0.964 2	—

5.4 多核 SSTCA 实验结果

5.4.1 多核实验对比分析

以 SVM 作为分类器, 利用 GA 优化其参数, 同时采用 10 倍交叉验证法进行实验, 将多核的 SSTCA 与不同单核核函数的 SSTCA 方法进行对比。实验中源域特征样本集(训练数据集)与目标域特征样本集(测试数据集)选取单工况或多工况数据集, 以 C/B 为例, 多核 SSTCA 中, 对各参数进行调节, 以获得最高测试准确率为目标, 经多次实验确定, 高斯径向基和多项式核参数均为 10, 多核系数 a 为 0.9, 正则化 μ 为 1, k 近邻取值为 200, 标准化局部参数 λ 为 120, 标签类别参数 γ 为 1000。对不同核函数以及不同工况进行实验, 测试变工况下滚动轴承 10 种状态分类的平均准确率见表 4。

表 4 不同核函数 SSTCA 变工况下
滚动轴承故障测试准确率

Tab. 4 Fault test accuracy for rolling bearings under
variable working conditions using
different kernel function SSTCA

不同核函数	准确率/%			平均准确率/%
	C/B	AC/BD	ACD/B	
Linear-SSTCA-SVM	78.00	67.35	78.88	74.74
Poly-SSTCA-SVM	92.22	92.90	96.77	93.96
Gaussian-SSTCA-SVM	59.11	52.45	59.44	57.00
Laplacian-SSTCA-SVM	79.22	70.85	82.00	77.35
多核 SSTCA-SVM	96.66	94.10	98.00	96.25

由表 4 可见, 无论单工况还是多工况数据集作为源域或目标域, 多核 SSTCA-SVM 方法的故障识别率均最高。很大原因在于多核核函数在处理源域数据和目标域数据不均衡时具备较好的优势。

5.4.2 多核 SSTCA 与其他算法对比分析

1) 基于变工况下滚动轴承振动特征, 对多核 SSTCA 与 KPCA、PCA 特征映射方法进行对比。

a) 对单工况/单工况(C/B)数据进行实验, 源域采用工况 C 的特征集, 目标域采用工况 B 的特征集, 经不同特征映射方法及 SVM 训练模型后, 得到测试结果如图 6 所示。

b) 对多工况/多工况(AC/BD)数据进行实验, 测试结果如图 7 所示。

c) 对多工况/单工况(ACD/B)数据进行实验, 测试结果如图 8 所示。

由图 6—8 可看出, 训练特征样本集与测试特征样本集维数从 1 增加到 12 时, 多核 SSTCA 与 KPCA、PCA 分别结合 SVM 的 3 种方法测试准确率不断提高。当维数超过 12 后, KPCA 和 PCA

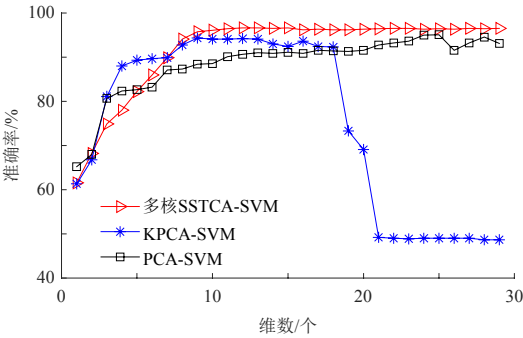


图 6 映射后的特征维数与准确率关系图(C/B)
Fig. 6 Relation graph between feature dimension and the
accuracy after mapping (C/B)




图 7 映射后的特征维数与准确率关系图(AC/BD)
Fig. 7 Relation graph between feature dimension and the
accuracy after mapping (AC/BD)




图 8 映射后的特征维数与准确率关系图(ACD/B)
Fig. 8 Relation graph between feature dimension and the
accuracy after mapping (ACD/B)

这 2 种方法的故障诊断测试准确率不高且有波动, 而多核 SSTCA 方法的诊断测试准确率总体保持平稳并略有提高, 并且均高于 KPCA 和 PCA 这 2 种方法。

2) 多核 SSTCA-SVM 与 TSVM、LapSVM 非迁移学习方法对比, 测试结果准确率见表 5。

由于 TSVM、LapSVM 非迁移学习方法直接用

表 5 多核 SSTCA-SVM 与非迁移学习方法
对比测试准确率

方法	C/B	AC/BD	ACD/B	平均准确率/%
TSVM	75.44	69.80	81.22	75.48
LapSVM	44.50	42.80	27.70	38.33
多核 SSTCA-SVM	96.66	94.10	98.00	96.25

源域数据训练模型，目标域数据测试模型，不能挖掘域间的共有特征信息，而多核 SSTCA-SVM 方法迁移源域数据已有知识到目标域，辅助目标域数据分类，由表 5 可见，该方法的测试准确率最高。

3) 多核 SSTCA 与最大独立域适应(maximum independence domain adaptation, MIDA)、SA、ITL、GFK、SSA 和迁移成分分析(transfer component analysis, TCA)领域适应性方法^[23]对比。分别用工况 C、AC、ACD 作为源域数据，用工况 B、BD、B 作为目标域数据，经各领域适应性方法和 SVM 分类器后得到结果见表 6。

表 6 不同领域适应性方法对比测试准确率

Tab. 6 Comparison test accuracy of different domain adaptation methods

不同领域适应性方法	C/B	AC/BD	ACD/B	平均准确率/%
MIDA-SVM	58.88	52.85	67.11	59.61
SA-SVM	59.22	41.35	61.88	54.15
ITL-SVM	94.55	87.35	95.66	92.52
GFK-SVM	12.33	10.00	10.00	10.77
SSA-SVM	18.77	19.70	10.60	16.35
TCA-SVM	60.70	52.75	64.11	59.18
多核 SSTCA-SVM	96.66	94.10	98.00	96.25

由表 6 可见，除了 ITL 方法能够在工况 C/B、ACD/B 上获得较好的测试结果外，其他领域适应性方法对变工况下滚动轴承数据适应性不强，准确率均不高。其中，TCA-SVM 方法的测试准确率也远低于多核 SSTCA-SVM 方法。其原因在于多核 SSTCA-SVM 利用 HSIC 方法提高特征样本与样本类别标签关联性，这有利于目标域数据的分类。另一方面，多核 SSTCA-SVM 方法的多核核函数对变工况下滚动轴承不平衡特征样本映射变换效果比其他方法要好，这有利于减小源域和目标域数据之间的分布差异。

6 结论

1) 提出结合 VMD 和 SVD 对滚动轴承振动信号进行奇异值特征提取，再与奇异值熵、振动信号时域、频域特征一起共同构建滚动轴承多域特征集的方法，从而获得更能表征滚动轴承状态的特征。

2) 引入 SSTCA 方法完成不同域间的迁移学习任务，并构造多核核函数的 SSTCA 方法提高变工况下滚动轴承振动特征映射能力，进而减小域间特征样本分布差异。

3) 采用最大均值差异嵌入方法衡量源域特征样本与目标域特征样本间的相似程度，并提出利用

最大均值差异统计值选择源域数据，提高对目标域数据测试的准确率。


4) 多核 SSTCA 方法与其他特征映射方法、领域适应性方法、非迁移学习方法对比。实验表明，多核 SSTCA-SVM 方法对变工况下滚动轴承未知状态识别效果更佳。

下一步工作将进一步研究迁移学习方法，探究变工况下滚动轴承各状态振动信号间的共有知识及多核 SSTCA 方法中参数优化问题，提高诊断准确率。

参考文献

- [1] 王玉静, 那晓栋, 康守强, 等. 基于 EEMD-Hilbert 包络谱和 DBN 的变负载下滚动轴承状态识别方法[J]. 中国电机工程学报, 2017, 37(23): 6943-6950.
Wang Yujing, Na Xiaodong, Kang Shouqiang, et al. State recognition method of a rolling bearing based on EEMD-Hilbert envelope spectrum and DBN under variable load [J]. Proceedings of the CSEE, 2017, 37(23): 6943-6950(in Chinese).
- [2] Liu Hongmei, Wang Xuan, Lu Chen. Rolling bearing fault diagnosis under variable conditions using Hilbert-Huang transform and singular value decomposition [J]. Mathematical Problems in Engineering, 2014: 765621.
- [3] Wu T Y, Yu C L, Liu D C. On multi-scale entropy analysis of order-tracking measurement for bearing fault diagnosis under variable speed[J]. Entropy, 2016, 18(8): 292.
- [4] Baraldi P, Cannarile F, Di Maio F, et al. Hierarchical k -nearest neighbours classification and binary differential evolution for fault diagnostics of automotive bearings operating under variable conditions[J]. Engineering Applications of Artificial Intelligence, 2016(56): 1-13.
- [5] Fei Shengwei. Fault diagnosis of bearing under varying load conditions by utilizing composite features self-adaptive reduction-based RVM classifier[J]. Journal of Vibration Engineering & Technologies, 2017, 5(3): 269-276.
- [6] Pan S J, Yang Qiang. A survey on transfer learning [J]. IEEE Transactions on Knowledge and Data Engineering, 2010, 22(10): 1345-1359.
- [7] 庄福振, 罗平, 何清, 等. 迁移学习研究进展[J]. 软件学报, 2015, 26(1): 26-39.
Zhuang Fuzhen, Luo Ping, He Qing, et al. Survey on transfer learning research[J]. Journal of Software, 2015, 26(1): 26-39(in Chinese).
- [8] 沈飞, 陈超, 严如强. 奇异值分解与迁移学习在电机故障诊断中的应用[J]. 振动工程学报, 2017, 30(1): 118-126.
Shen Fei, Chen Chao, Yan Ruqiang. Application of SVD and transfer learning strategy on motor fault diagnosis [J]. Journal of Vibration Engineering, 2017, 30(1): 118-126(in Chinese).

- [9] 陈超, 沈飞, 严如强. 改进 LSSVM 迁移学习方法的轴承故障诊断[J]. 仪器仪表学报, 2017, 38(1): 33-40.
Chen Chao, Shen Fei, Yan Ruqiang. Enhanced least squares support vector machine-based transfer learning strategy for bearing fault diagnosis[J]. Chinese Journal of Scientific Instrument, 2017, 38(1): 33-40(in Chinese).
- [10] 韩敏, 杨雪. 改进贝叶斯 ARTMAP 的迁移学习遥感影像分类算法[J]. 电子学报, 2016, 44(9): 2248-2253.
Han Min, Yang Xue. Transfer learning using improved Bayesian ARTMAP for remote sensing image classification[J]. Acta Electronica Sinica, 2016, 44(9): 2248-2253(in Chinese).
- [11] Dai Wenyuan, Yang Qiang, Xue Guirong, et al. Boosting for transfer learning[C]//Proceedings of the 24th International Conference on Machine Learning. Corvallis, Oregon, USA: ACM, 2007: 193-200.
- [12] Matasci G, Volpi M, Kanevski M, et al. Semisupervised transfer component analysis for domain adaptation in remote sensing image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2015, 53(7): 3550-3564.
- [13] Von Büna P, Meinecke F C, Király F C, et al. Finding stationary subspaces in multivariate time series [J]. Physical Review Letters, 2009, 103(21): 214101.
- [14] Shi Yuan, Sha Fei. Information-theoretical learning of discriminative clusters for unsupervised domain adaptation[C]//Proceedings of the 29th International Conference on International Conference on Machine Learning. Edinburgh, Scotland: Omnipress, 2012: 1275-1282.
- [15] Gong Boqing, Shi Yuan, Sha Fei, et al. Geodesic flow kernel for unsupervised domain adaptation[C]//Proceedings of 2012 IEEE Conference on Computer Vision and Pattern Recognition. Providence, RI, USA: IEEE, 2012: 2066-2073.
- [16] Fernando B, Habrard A, Sebban M, et al. Unsupervised visual domain adaptation using subspace alignment[C]//Proceedings of 2013 IEEE International Conference on Computer Vision. Sydney, NSW, Australia: IEEE, 2013: 2960-2967.
- [17] 刘长良, 武英杰, 甄成刚. 基于变分模态分解和模糊 C 均值聚类的滚动轴承故障诊断[J]. 中国电机工程学报, 2015, 35(13): 3358-3365.
Liu Changliang, Wu Yingjie, Zhen Chenggang. Rolling bearing fault diagnosis based on variational mode decomposition and fuzzy C means clustering [J]. Proceedings of the CSEE, 2015, 35(13): 3358-3365(in Chinese).
- [18] 赵学智, 陈统坚, 叶邦彦. 奇异值分解对连续 Morlet 小波变换的压缩和提纯[J]. 机械工程学报, 2015, 51(16): 57-70.
Zhao Xuezhi, Chen Tongjian, Ye Bangyan. Purification and compression of continuous morlet wavelet transform based on singular value decomposition[J]. Journal of Mechanical Engineering, 2015, 51(16): 57-70(in Chinese).
- [19] 毋文峰, 李浩, 朱露. 基于奇异值融合的机械设备盲信息提取[J]. 中国机械工程, 2015, 26(22): 3028-3033.
Wu Wenfeng, Li Hao, Zhu Lu. Blind mechanical information extraction based on singular value fusion [J]. China Mechanical Engineering, 2015, 26(22): 3028-3033(in Chinese).
- [20] 康守强, 王玉静, 崔历历, 等. 基于 CFOA-MKHSVM 的滚动轴承健康状态评估方法[J]. 仪器仪表学报, 2016, 37(9): 2029-2035.
Kang Shouqiang, Wang Yujing, Cui Lili, et al. Health state assessment of a rolling bearing based on CFOA-MKHSVM method[J]. Chinese Journal of Scientific Instrument, 2016, 37(9): 2029-2035(in Chinese).
- [21] Damodaran B B, Courty N, Lefèvre S. Sparse Hilbert Schmidt independence criterion and surrogate-kernel-based feature selection for hyperspectral image classification[J]. IEEE Transactions on Geoscience and Remote Sensing, 2017, 55(4): 2385-2398.
- [22] Kang Shouqiang, Ma Danyang, Wang Yujing, et al. Method of assessing the state of a rolling bearing based on the relative compensation distance of multiple-domain features and locally linear embedding[J]. Mechanical Systems and Signal Processing, 2017(86): 40-57.
- [23] Yan Ke, Kou Lu, Zhang D. Learning domain-invariant subspace using domain features and independence maximization[J]. IEEE Transactions on Cybernetics, 2018, 48(1): 288-299.



康守强

收稿日期: 2018-05-12.

作者简介:

康守强(1980), 男, 博士, 教授, 主要研究方向为非平稳信号处理, 故障诊断、状态评估与预测技术, kangshouqiang@163.com;

胡明武(1992), 男, 硕士研究生, 主要研究方向为非平稳信号处理, 故障诊断、状态评估与预测技术, 843553107@qq.com;

王玉静(1983), 女, 博士, 副教授, 主要研究方向为非平稳信号处理, 故障诊断、状态评估与预测技术, mirrorwyj@163.com;

谢金宝(1980), 男, 博士, 副教授, 主要研究方向为机器学习、深度学习, jbxpost@163.com;

Mikulovich V.I.(1946), 男, 教授, 博士生导师, 研究方向为机械故障诊断, 信号与信息处理。

(责任编辑 王庆霞)

Fault Diagnosis Method of a Rolling Bearing Under Variable Working Conditions Based on Feature Transfer Learning

KANG Shouqiang¹, HU Mingwu¹, WANG Yujing¹, XIE Jinbao¹, V.I. Mikulovich²

(1. Harbin University of Science and Technology; 2. Belarusian State University)

Key words: variable working conditions; rolling bearing; semisupervised transfer component analysis(SSTCA); transfer learning; variational mode decomposition(VMD)

For a rolling bearing, especially under variable working conditions, it is difficult and even unable to obtain a large number of tagged vibration data, and then the fault diagnosis accuracy is low; therefore, a multi-state recognition method for a rolling bearing is proposed.

By using variational mode decomposition (VMD), each state vibration signal of the rolling bearing is decomposed into a series of intrinsic mode function (IMF) components, then the singular values of the IMF matrix can be obtained by singular value decomposition, and the singular value entropy can be calculated. The multiple feature set is constructed with the singular values, the singular value entropy, the time domain and frequency domain features.

At the same time, semisupervised transfer component analysis (SSTCA) is introduced, and its kernel is constructed as the multi-kernel function. The sample features of different working conditions are all mapped to a shared reproducing kernel Hilbert space, which can improve the compactness and interclass distinction of the data. And by using the maximum mean discrepancy embedding method, more effective data are selected and regarded as the source domain. The source domain feature samples are input into support vector machine (SVM), then the feature samples of the mapped target domain are tested, and multi-state classification of the rolling bearing under variable working conditions can be achieved.

The proposed method is applied to recognize the rolling bearing data, 10 states of normal, different fault locations and different performance degradation degrees, and each state contains 4 loads and 4 rotational speeds. In the experiments, A/B/C/D are respectively regarded as the feature sample set under working conditions 0hp 1797r/min, 1 hp 1772r/min, 2hp 1750r/min and 3 hp 1730r/min. And by using the maximum mean discrepancy embedding method, the known working condition data which has high similarity to the measured working condition data is selected and regarded as the training data. Rolling bearing multi-state under variable working conditions includes C/B, AC/BD and ACD/B, and the experiments are done.

Under different single kernel function SSTCA conditions, the multi-kernel SSTCA (MKSSTCA) is proposed combining Polynomials and Gauss radial basis, then the highest test accuracy can be obtained. It indicates that the multi-kernel function has a better advantage in dealing with the imbalance of source domain and the target domain data. By comparing with non-transfer learning methods KPCA and PCA, taking the working condition (ACD/B) as an example, as shown in Fig.1, MKSSTCA overall keeps the highest test accuracy. Furthermore, compared with TSVM and LapSVM, MKSSTCA-SVM has the highest test accuracy as well.




Fig. 1 Relation graph[0] between feature dimension and the accuracy after mapping(ACD/B)

Further, compared with other domain adaptation methods, by using MKSSTCA method, the highest test accuracy can be obtained, and the results are shown in Tab.1.

Tab. 1 Comparison test accuracy of different domain adaptation methods

Different domain adaptation methods	Accuracy/%			Average accuracy/%
	C/B	AC/BD	ACD/B	
MIDA-SVM	58.88	52.85	67.11	59.61
SA-SVM	59.22	41.35	61.88	54.15
ITL-SVM	94.55	87.35	95.66	92.52
GFK-SVM	12.33	10.00	10.00	10.77
SSA-SVM	18.77	19.70	10.60	16.35
TCA-SVM	60.70	52.75	64.11	59.18
MKSSTCA-SVM	96.66	94.10	98.00	96.25

In summary, by comparing the proposed MKSSTCA method with other feature mapping method, domain adaptation method, non-transfer learning method, the experiment results show that MKSSTCA-SVM method can better recognize the unknown state of the rolling bearing under variable working conditions.